



Presentación de Minería de Datos

Spotify Tracks Dataset

Rafael Contreras Agudelo
Edwyn Guzmán
Yarima Contreras Blanco

6213 - Minería de Datos
Facultad de ciencias
Universidad Central de Venezuela

11 de marzo de 2026

Contenido

- 1 Definición del Potencial de Mercado
- 2 Estrategia: Metodología CRISP-DM
- 3 Definición del Reto Comercial y Análisis del Inventario de Datos
- 4 Garantía de Calidad y Fiabilidad de la Información
- 5 Descubrimiento de los Atributos de Popularidad
- 6 Validación de la Capacidad de Predicción
- 7 Estrategia Basada en Evidencia para el Éxito de Contenidos

"La música es la aritmética de los sonidos, como la óptica es la geometría de la luz."^a

^aClaude Debussy

Definición del Potencial de Mercado

Introducción: Contexto del Negocio

- ▶ **Decisión de Inversión:** En la industria musical, predecir si un track será un éxito es vital para determinar el destino de los recursos.
- ▶ **Plataformas Digitales:** Spotify genera millones de puntos de datos diarios sobre el comportamiento del usuario.
- ▶ **Competitividad:** Con miles de lanzamientos diarios, destacar un track requiere más que solo intuición artística.

Oportunidad

El uso de **Minería de Datos** permite transformar características musicales en ventajas competitivas para sellos y artistas.

Definición del Problema

Desafío Predecir el éxito (popularidad) de una canción antes o durante su lanzamiento.

Incertidumbre Las inversiones en marketing musical suelen ser de alto riesgo sin un respaldo analítico de los datos.

Pregunta de Investigación:

¿Es posible determinar el *ranking* de una canción basándose en sus atributos técnicos como el tempo, la energía y la bailabilidad?

Objetivos

Objetivo General:

- ▶ Aplicar el proceso de minería de datos para predecir el ranking de tracks de Spotify utilizando la metodología CRISP-DM.

Objetivos Específicos:

- ▶ Ejecutar el preprocesamiento y limpieza del dataset.
- ▶ Realizar un análisis exploratorio de datos (EDA) para identificar patrones y relaciones entre variables.
- ▶ Desarrollar un modelo predictivo para pronosticar el ranking de una canción.

Estrategia: Metodología CRISP-DM

Metodología CRISP-DM: Características

- **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Metodología CRISP-DM: Características

- ▶ **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- ▶ **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- ▶ **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Metodología CRISP-DM: Características

- ▶ **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- ▶ **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- ▶ **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Justificación de la Metodología

Motivo de elección

Se selecciona esta metodología por su capacidad para estructurar un proceso completo desde la comprensión del negocio y de los datos técnicos hasta la predicción de resultados.

Ventajas de su utilización:

1. **Flexibilidad:** Ideal para ajustar el preprocesamiento de variables acústicas según los hallazgos del EDA.
2. **Evaluación Continua:** Permite validar si las métricas de regresión responden correctamente a la meta de negocio (predecir el ranking).
3. **Estructura:** Facilita la transición entre el análisis exploratorio y el modelado de regresión propuesto.

Definición del Reto Comercial y Análisis del Inventario de Datos

Fase I: Comprensión del Negocio

Propuesta de Valor Analítica

Transformar los atributos acústicos de los tracks en un valor numérico de **popularity** mediante un modelo de **regresión**, permitiendo predecir el rendimiento comercial de una canción.

Criterios de Éxito del Proyecto:

- ▶ **Técnico:** Lograr un modelo con un margen de error aceptable que permita diferenciar canciones con alto potencial de aquellas con bajo impacto.
- ▶ **De Negocio:** Identificar los patrones históricos que correlacionan el "sonido" (variables flotantes) con el éxito, para reducir el riesgo en la toma de decisiones de inversión.

Meta Final:

Generar una herramienta analítica que determine si una canción será un éxito basándose en su composición técnica.

Fase II: Comprensión de los Datos

Origen de los datos: Spotify Tracks Dataset ([Kaggle](#)).

- **Observaciones:** 114.000 registros.
- **Variables:** 21 columnas.

Dimensiones del Análisis:

Tipo de Dato	Variables
Entero (int64)	#, popularity, duration_ms, key, mode, time_signature
Texto (object)	track_id, artists, album_name, track_name, track_genre
Lógico (bool)	explicit
Flotante (float64)	danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo

Tabla: Tipos de datos por columna del dataset escogido.

Fase II: Comprensión de los Datos

Previsualización de los Datos:

Unnamed: 0		track_id	artists	album_name	track_name	popularity	duration_ms	explicit	danceability	energy
0	0	5SuOikwIRyPMVolQDJUgSV	Gen Hoshino	Comedy	Comedy	73	230666	False	0.676	0.4610
1	1	4qPNDBW1i3p13qLCi0Ki3A	Ben Woodward	Ghost (Acoustic)	Ghost - Acoustic	55	149610	False	0.420	0.1660
2	2	1UBSr7s7jYXzM8EGcbK5b	Ingrid Michaelson,ZAYN	To Begin Again	To Begin Again	57	210826	False	0.438	0.3590
3	3	6lfxq3CG4xtTIEg7opyCyx	Kina Grannis	Crazy Rich Asians (Original Motion Picture Sou...	Can't Help Falling In Love	71	201933	False	0.266	0.0596
4	4	5vjLSffimIP26QG5WcN2K	Chord Overstreet	Hold On	Hold On	82	198853	False	0.618	0.4430
key	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature	track_genre
1	-6.746	0	0.1430	0.0322	0.000001	0.3580	0.715	87.917	4	acoustic
1	-17.235	1	0.0763	0.9240	0.000006	0.1010	0.267	77.489	4	acoustic
0	-9.734	1	0.0557	0.2100	0.000000	0.1170	0.120	76.332	4	acoustic
0	-18.515	1	0.0363	0.9050	0.000071	0.1320	0.143	181.740	3	acoustic
2	-9.681	1	0.0526	0.4690	0.000000	0.0829	0.167	119.949	4	acoustic

Figura: Impresión de los primeros registros del dataset.

Garantía de Calidad y Fiabilidad de la Información

Preprocesamiento: Valores Faltantes

	Nulos	Porcentaje (%)
artists	1	0.000877
track_name	1	0.000877
album_name	1	0.000877
Unnamed: 0	0	0.000000
track_id	0	0.000000
popularity	0	0.000000
duration_ms	0	0.000000
explicit	0	0.000000
danceability	0	0.000000
energy	0	0.000000
key	0	0.000000
loudness	0	0.000000
mode	0	0.000000
speechiness	0	0.000000
acousticness	0	0.000000
instrumentalness	0	0.000000
liveness	0	0.000000
valence	0	0.000000
tempo	0	0.000000
time_signature	0	0.000000
track_genre	0	0.000000

Tratamiento de Datos:

- **Limpieza Inicial:** Identificación de valores nulos en cada campo del dataset.
- **Estrategia:** Dado el bajo porcentaje de nulos y su poca relevancia para el análisis, se opta por eliminar las filas con valores faltantes. Esto también permite la utilización de un modelo de regresión.

Figura: Cantidad y porcentaje de valores faltantes por columna.

Preprocesamiento: Valores Faltantes

	Nulos	Porcentaje (%)
artists	1	0.000877
track_name	1	0.000877
album_name	1	0.000877
Unnamed: 0	0	0.000000
track_id	0	0.000000
popularity	0	0.000000
duration_ms	0	0.000000
explicit	0	0.000000
danceability	0	0.000000
energy	0	0.000000
key	0	0.000000
loudness	0	0.000000
mode	0	0.000000
speechiness	0	0.000000
acousticness	0	0.000000
instrumentalness	0	0.000000
liveness	0	0.000000
valence	0	0.000000
tempo	0	0.000000
time_signature	0	0.000000
track_genre	0	0.000000

Figura: Cantidad y porcentaje de valores faltantes por columna.

Tratamiento de Datos:

- **Limpieza Inicial:** Identificación de valores nulos en cada campo del dataset.
- **Estrategia:** Dado el bajo porcentaje de nulos y su poca relevancia para el análisis, se opta por eliminar las filas con valores faltantes. Esto también permite la utilización de un modelo de regresión.

Preprocesamiento: Variables No Relevantes

- **Limpieza de nulos:** Se ejecuta la eliminación de filas con valores faltantes.
- **Limpieza de variables no relevantes:** Se descartan las columnas que no aportan información útil para el modelo predictivo, como los IDs, nombres y géneros de canciones.

Dimensiones resultantes: 113.999 registros y 14 columnas.

```
# Eliminar filas con valores nulos (NaN)
df_clean = df.dropna()

# Eliminar variables de identificación y texto libre (Ruido)
columnas_a_eliminar = ['Unnamed: 0', 'track_id', 'artists', 'album_name', 'track_name', 'track_genre', 'key']
df_clean = df_clean.drop(columns=columnas_a_eliminar)

print(f"Dimensiones tras la limpieza: {df_clean.shape}")
```

Dimensiones tras la limpieza: (113999, 14)

Figura: Limpieza Estructural del Dataset.

Preprocesamiento: Valores Lógicos

- **Valores Lógicos:** Los modelos de regresión necesitan variables numéricas. Por esta razón, se transforman los valores booleanos de la columna `explicit` a 0 (no explícito) y 1 (explícito).

	popularity	duration_ms	explicit	danceability	energy	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	73	230666	0	0.676	0.4610	-6.746	0	0.1430	0.0322	0.000001	0.3580	0.7150	87.917	4
1	55	149610	0	0.420	0.1660	-17.235	1	0.0763	0.9240	0.000006	0.1010	0.2670	77.489	4
2	57	210826	0	0.438	0.3590	-9.734	1	0.0557	0.2100	0.000000	0.1170	0.1200	76.332	4
3	71	201933	0	0.266	0.0596	-18.515	1	0.0363	0.9050	0.000071	0.1320	0.1430	181.740	3
4	82	198853	0	0.618	0.4430	-9.681	1	0.0526	0.4690	0.000000	0.0829	0.1670	119.949	4
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
113995	21	384999	0	0.172	0.2350	-16.393	1	0.0422	0.6400	0.928000	0.0863	0.0339	125.995	5
113996	22	385000	0	0.174	0.1170	-18.318	0	0.0401	0.9940	0.976000	0.1050	0.0350	85.239	4
113997	22	271466	0	0.629	0.3290	-10.895	0	0.0420	0.8670	0.000000	0.0839	0.7430	132.378	4
113998	41	283893	0	0.587	0.5060	-10.889	1	0.0297	0.3810	0.000000	0.2700	0.4130	135.960	4
113999	22	241826	0	0.526	0.4870	-10.204	0	0.0725	0.6810	0.000000	0.0893	0.7080	79.198	4

113999 rows x 14 columns

Figura: Transformación de Booleanos.

Descubrimiento de los Atributos de Popularidad

EDA: Estadísticas Descriptivas

Descriptores estadísticos de media, mediana, desviación estándar, mínimo y máximo para cada variable numérica del dataset.

- **Popularidad:**
Media de 33.2 con alta desviación estándar, indicando una gran dispersión en el éxito de los tracks.

	media	mediana	desv_estandar	min	max
popularity	33.238535	35.000000	22.305078	0.000	100.000
duration_ms	228029.153114	212906.000000	107297.712645	0.000	5237295.000
danceability	0.566800	0.580000	0.173542	0.000	0.985
energy	0.641383	0.685000	0.251529	0.000	1.000
key	5.309140	5.000000	3.559987	0.000	11.000
loudness	-8.258960	-7.004000	5.029337	-49.531	4.532
mode	0.637553	1.000000	0.480709	0.000	1.000
speechiness	0.084652	0.048900	0.105732	0.000	0.965
acousticness	0.314910	0.169000	0.332523	0.000	0.996
instrumentalness	0.156050	0.000042	0.309555	0.000	1.000
liveness	0.213553	0.132000	0.190378	0.000	1.000
valence	0.474068	0.464000	0.259261	0.000	0.995
tempo	122.147837	122.017000	29.978197	0.000	243.372
time_signature	3.904035	4.000000	0.432621	0.000	5.000

Figura: Estadísticas descriptivas.

EDA: Estadísticas Descriptivas

Descriptores estadísticos de media, mediana, desviación estándar, mínimo y máximo para cada variable numérica del dataset.

- **Duración:** El promedio se sitúa en ≈ 228 s (3.8 min). Se detectan valores máximos extremos que sugieren presencia de *outliers*.

	media	mediana	desv_estandar	min	max
popularity	33.238535	35.000000	22.305078	0.000	100.000
duration_ms	228029.153114	212906.000000	107297.712645	0.000	5237295.000
danceability	0.566800	0.580000	0.173542	0.000	0.985
energy	0.641383	0.685000	0.251529	0.000	1.000
key	5.309140	5.000000	3.559987	0.000	11.000
loudness	-8.258960	-7.004000	5.029337	-49.531	4.532
mode	0.637553	1.000000	0.480709	0.000	1.000
speechiness	0.084652	0.048900	0.105732	0.000	0.965
acousticness	0.314910	0.169000	0.332523	0.000	0.996
instrumentalness	0.156050	0.000042	0.309555	0.000	1.000
liveness	0.213553	0.132000	0.190378	0.000	1.000
valence	0.474068	0.464000	0.259261	0.000	0.995
tempo	122.147837	122.017000	29.978197	0.000	243.372
time_signature	3.904035	4.000000	0.432621	0.000	5.000

Figura: Estadísticas descriptivas.

EDA: Estadísticas Descriptivas

Descriptores estadísticos de media, mediana, desviación estándar, mínimo y máximo para cada variable numérica del dataset.

- **Variabilidad:** La amplitud de rangos en *energy* y *danceability* asegura una base de aprendizaje diversa para el modelo de regresión.

	media	mediana	desv_estandar	min	max
popularity	33.238535	35.000000	22.305078	0.000	100.000
duration_ms	228029.153114	212906.000000	107297.712645	0.000	5237295.000
danceability	0.566800	0.580000	0.173542	0.000	0.985
energy	0.641383	0.685000	0.251529	0.000	1.000
key	5.309140	5.000000	3.559987	0.000	11.000
loudness	-8.258960	-7.004000	5.029337	-49.531	4.532
mode	0.637553	1.000000	0.480709	0.000	1.000
speechiness	0.084652	0.048900	0.105732	0.000	0.965
acousticness	0.314910	0.169000	0.332523	0.000	0.996
instrumentalness	0.156050	0.000042	0.309555	0.000	1.000
liveness	0.213553	0.132000	0.190378	0.000	1.000
valence	0.474068	0.464000	0.259261	0.000	0.995
tempo	122.147837	122.017000	29.978197	0.000	243.372
time_signature	3.904035	4.000000	0.432621	0.000	5.000

Figura: Estadísticas descriptivas.

EDA: Análisis de Distribución

Se tiene que $y \in \mathbb{R}^n$, con $y_i \in [0, 100]$ representa la popularidad real de una canción i . Su distribución permite observar su comportamiento para la toma de decisiones.




Figura: Distribución de la popularidad.

EDA: Análisis de Distribución




Figura: Distribución de la popularidad.

- **Distribución Asimétrica:** Se observa un sesgo positivo (*Right-Skewed*), con una alta concentración en el rango $[0, 50]$.
- **Fenómeno Long-Tail:** La presencia de "éxitos" (popularidad > 80) es estadísticamente baja, reflejando la realidad del mercado musical.
- **Punto Crítico (Popularidad 0):** Existe un pico en el valor mínimo, atribuible a lanzamientos recientes o nichos sin tracción comercial.

EDA: Análisis de Distribución




Figura: Distribución de la popularidad.

- **Distribución Asimétrica:** Se observa un sesgo positivo (*Right-Skewed*), con una alta concentración en el rango $[0, 50]$.
- **Fenómeno Long-Tail:** La presencia de "éxitos" (popularidad > 80) es estadísticamente baja, reflejando la realidad del mercado musical.
- **Punto Crítico (Popularidad 0):** Existe un pico en el valor mínimo, atribuible a lanzamientos recientes o nichos sin tracción comercial.

EDA: Análisis de Distribución




Figura: Distribución de la popularidad.

- **Distribución Asimétrica:** Se observa un sesgo positivo (*Right-Skewed*), con una alta concentración en el rango $[0, 50]$.
- **Fenómeno Long-Tail:** La presencia de "éxitos" (popularidad > 80) es estadísticamente baja, reflejando la realidad del mercado musical.
- **Punto Crítico (Popularidad 0):** Existe un pico en el valor mínimo, atribuible a lanzamientos recientes o nichos sin tracción comercial.

EDA: Análisis de Correlación

Se implementa un Heatmap para visualizar la matriz de correlación entre las variables numéricas del dataset, con el objetivo de identificar relaciones lineales que puedan ser aprovechadas por el modelo de regresión.




Figura: Matriz de correlación.

EDA: Análisis de Correlación




Figura: Matriz de correlación.

- **Multicolinealidad:** Se observa una fuerte correlación positiva entre *energy* y *loudness*.
- **Relación con el Target:** La popularidad no muestra una dependencia lineal fuerte con una única variable.
- **Correlación Negativa:** Atributos como *acousticness* e *instrumentalness* tienden a oponerse a la energía del track.

EDA: Análisis de Correlación




Figura: Matriz de correlación.

- **Multicolinealidad:** Se observa una fuerte correlación positiva entre *energy* y *loudness*.
- **Relación con el Target:** La popularidad no muestra una dependencia lineal fuerte con una única variable.
- **Correlación Negativa:** Atributos como *acousticness* e *instrumentalness* tienden a oponerse a la energía del track.

EDA: Análisis de Correlación




Figura: Matriz de correlación.

- **Multicolinealidad:** Se observa una fuerte correlación positiva entre *energy* y *loudness*.
- **Relación con el Target:** La popularidad no muestra una dependencia lineal fuerte con una única variable.
- **Correlación Negativa:** Atributos como *acousticness* e *instrumentalness* tienden a oponerse a la energía del track.

EDA: Análisis de Correlación

Para el par de variables con mayor correlación positiva, se realiza un análisis de dispersión para evaluar la relación lineal entre ellas.




Figura: Análisis de dispersión entre *energy* y *loudness*.

EDA: Análisis de Correlación




Figura: Análisis de dispersión entre *energy* y *loudness*.

- **Multicolinealidad Detectada:** Alta correlación positiva entre *energy* y *loudness*. Se evaluará el uso de solo una para evitar redundancia en el modelo.
- **Outliers Técnicos:** Los puntos aislados en la zona inferior derecha representan tracks con alta energía pero bajo volumen, posibles errores de medición o grabaciones deliberadas.

EDA: Análisis de Correlación




Figura: Análisis de dispersión entre *energy* y *loudness*.

- **Multicolinealidad Detectada:** Alta correlación positiva entre *energy* y *loudness*. Se evaluará el uso de solo una para evitar redundancia en el modelo.
- **Outliers Técnicos:** Los puntos aislados en la zona inferior derecha representan tracks con alta energía pero bajo volumen, posibles errores de medición o grabaciones deliberadas.

EDA: Relación entre Atributos Acústicos y Popularidad

Con el objetivo de revelar dónde está el consenso del mercado y cuáles son los patrones técnicos de los éxitos comerciales en Spotify, se presentan los siguientes gráficos de dispersión:

Análisis de Impulsores de Popularidad: Relación entre Atributos Acústicos y Éxito




Figura: Relación entre Atributos Acústicos y Popularidad.

EDA: Relación entre Atributos Acústicos y Popularidad

1. Intensidad (Loudness/Energy)

- ▶ Tendencia de **energy** > 0.5 .
- ▶ Concentración de **loudness** entre -10 y 0 dB.
- ▶ El oyente busca una **experiencia sonora vibrante**.

3. Versatilidad (Valence/Tempo/Danceab.)

- ▶ Indiferencia ante el **tempo** o el sentimiento (triste/alegre).
- ▶ Aunque hay sesgo hacia lo **bailable** (danceability), existen éxitos en todo el espectro.

2. Estructura (Duration/Instrum.)

- ▶ El éxito se desploma fuera de los **3 min** (200k ms).
- ▶ Barrera clara para temas sin voz; la popularidad masiva requiere **instrumentalness** ≈ 0 .

4. Autenticidad (Speech./Acous.)

- ▶ Rechazo a niveles altos de **speechiness** (podcasts).
- ▶ Preferencia por grabaciones de **estudio** (**liveness** < 0.4) y sonidos menos orgánicos.

EDA: Análisis de Valores Atípicos (Outliers)

Se implementa un gráfico de caja y bigotes para identificar la presencia de valores atípicos en variables con escalas físicas, como `duration_ms`, `tempo`, `loudness` y `speechiness` que podrían afectar el rendimiento del modelo de regresión.




Figura: Gráfico de caja y bigotes para identificar valores atípicos.

EDA: Análisis de Valores Atípicos (Outliers)

► Ruido en Escalas Temporales

- `duration_ms`: Valores extremos, posiblemente pertenecientes a mixtypes o podcasts, desplazan la línea de regresión, penalizando el error en canciones estándar.

► Desviación de Estándares Comerciales

- `loudness` y `tempo`: Tracks con volumen casi nulo o ritmos extremos no compiten en el mercado musical actual.

► Filtrado por Contenido

- `speechiness`: Outliers superiores delatan contenido no musical (podcasts/lecturas), lo cual es ruido para el objetivo planteado.




Figura: Anomalías en duración.

EDA: Análisis de Valores Atípicos (Outliers)

► Ruido en Escalas Temporales

- `duration_ms`: Valores extremos, posiblemente pertenecientes a mixtypes o podcasts, desplazan la línea de regresión, penalizando el error en canciones estándar.

► Desviación de Estándares Comerciales

- `loudness` y `tempo`: Tracks con volumen casi nulo o ritmos extremos no compiten en el mercado musical actual.

► Filtrado por Contenido

- `speechiness`: Outliers superiores delatan contenido no musical (podcasts/lecturas), lo cual es ruido para el objetivo planteado.




Figura: Desbalance en audio y ritmo.

EDA: Análisis de Valores Atípicos (Outliers)

► Ruido en Escalas Temporales

- `duration_ms`: Valores extremos, posiblemente pertenecientes a mixtypes o podcasts, desplazan la línea de regresión, penalizando el error en canciones estándar.

► Desviación de Estándares Comerciales

- `loudness` y `tempo`: Tracks con volumen casi nulo o ritmos extremos no compiten en el mercado musical actual.

► Filtrado por Contenido

- `speechiness`: Outliers superiores delatan contenido no musical (podcasts/lecturas), lo cual es ruido para el objetivo planteado.




Figura: Detección de contenido hablado.

Decisiones de Tratamiento




Figura: Reducción de ceros en la distribución.

► Tratamiento del Sesgo (Target)


- Eliminación de registros con popularidad 0, se mantuvo el 15 % para evitar el sesgo predictivo.

► Selección de Características

- Remoción de loudness por multicolinealidad con energy.
- Exclusión de key debido a su nula correlación con el éxito.

Decisiones de Tratamiento

Variable eliminada por alta multicolinealidad: ['loudness']
Nuevas dimensiones del dataset: (10000, 14)



► Tratamiento del Sesgo (Target)

- Eliminación de registros con popularidad 0, se mantuvo el 15 % para evitar el sesgo predictivo.

► Selección de Características

- Remoción de loudness por multicolinealidad con energy.
- Exclusión de key debido a su nula correlación con el éxito.

Figura: Matriz de características optimizada.

Decisiones de Tratamiento




Figura: Filtrado de valores atípicos.

► Filtrado de Valores Atípicos

- Filtrado de outliers en `duration_ms`, `loudness`, `tempo` y `speechiness` para eliminar lo que no es una canción.
- Se opta por mantener música comercial, para evitar confusiones con podcasts o música ambiental.

► Partición y Escalado

- División 80/20 (Train/Test).
- *StandardScaler* para normalizar magnitudes y evitar el *Data Leakage*.

Decisiones de Tratamiento

Partición del Dataset (Train/Test Split)




Figura: Preparación de datos para entrenamiento.

► Filtrado de Valores Atípicos

- Filtrado de outliers en `duration_ms`, `loudness`, `tempo` y `speechiness` para eliminar lo que no es una canción.
- Se opta por mantener música comercial, para evitar confusiones con podcasts o música ambiental.

► Partición y Escalado

- División 80/20 (Train/Test).
- *StandardScaler* para normalizar magnitudes y evitar el *Data Leakage*.

Distancia Semántica: Categorías

¿Por qué estudiar variables textuales?

- ▶ Los atributos acústicos (energy, tempo, loudness, ...) ignoran la **carga emocional** y temática del título (*track_name*) de la canción.
- ▶ Los nombres de las canciones contienen metadatos implícitos sobre el mercado y el sentimiento del oyente.

Metodología: Embeddings y Distancia de Coseno

- ▶ Transformar el texto en vectores de alta dimensión mediante modelos de lenguaje Transformer.
- ▶ Calcular la distancia semántica entre el nombre de cada track y categorías estratégicas: *Amor*, *Fiesta* y *Tristeza*.
- ▶ **Objetivo:** Cuantificar qué tanto se acerca una canción a un concepto temático para usarlo como predictor numérico.

Implementación de Embedding

Flujo de Trabajo:

1. **Vectorización:** Uso de Sentence-Transformers multilingües.
2. **Ingeniería de Características:** Inyección de 3 nuevas columnas al dataset original.
3. **Escalamiento:** Re-ajuste de la matriz mediante StandardScaler para integrar las distancias.

Muestra aleatoria:

	track_name	party_distance	sadness_distance	love_distance
88400	Hawai - Remix	0.170947	0.029901	0.102261
36545	Je regrette	0.024772	0.273103	0.072270
91086	Christmas Without You	0.201745	0.266203	0.089456
58678	Fat Fuck	0.144887	0.036792	0.013596
88628	Ova Dweet (Mixed)	0.265936	0.065190	0.036952
48927	True Love	0.172046	0.307290	0.580225
61090	BPM170の君へ	0.028720	0.011558	0.009332
89722	Prohibidox	0.036200	0.101982	0.019636
12188	欲望の断片	0.138452	0.314074	0.087578
103711	Never In The Middle	0.045821	0.141254	0.094069

Figura: Previsualización de resultados con muestra aleatoria.

Top 5 Canciones por Categoría

1. Modelo
paraphrase-multilingual-
MiniLM-L12-v2.
2. Identificación de
términos en español,
inglés y portugués.
3. Detección de sinónimos
semánticos.

--- Top 5 Canciones con mayor 'love_distance' ---

	track_name	love_distance
90263	Amor de los dos	0.761608
15352	Love Affair	0.760012
103906	Love Affair	0.760012
90697	El amor es para los dos	0.755456
107302	romantics	0.731767

--- Top 5 Canciones con mayor 'sadness_distance' ---

	track_name	sadness_distance
45939	Tristeza e Solidão	0.847848
6780	Travels to Sadness, Hate & Depression	0.818483
5468	Sadness and Sorrow	0.817248
5174	Sadness and Sorrow	0.817248
56320	this is what sadness feels like	0.785922

--- Top 5 Canciones con mayor 'party_distance' ---

	track_name	party_distance
66125	Dance Party in the House	0.807558
13222	Dance - Club Mix	0.790647
45319	Night Dance	0.772010
107283	Dance Hall Days	0.763810
61445	The World Standard Dancing Club	0.759475

Figura: Top 5 por Categoría.

Correlación: Dimensiones Semánticas y Popularidad

1. Relación lineal muy baja: el nombre de la canción por sí solo no predice el éxito comercial.
2. Correlación de 0.44 entre `sadness_distance` y `love_distance`.
3. Mezcla de sentimientos de tristeza y amor (desamor).




Figura: Correlación Dimensiones Semánticas.

Validación de la Capacidad de Predicción

Paradigma y Justificación del Modelo

El desafío de predecir la popularidad de una canción usando de base sus atributos técnicos se aborda mediante un modelo de **regresión lineal**.

Regresión Lineal

Es un modelo matemático que busca representar una relación lineal entre una variable dependiente **Y** y una o más variables independientes **X**.

Matemáticamente, se expresa como: $Y = X\beta + \epsilon$

Para este caso, se tiene que:

- ▶ **Y**: Popularidad de la canción (variable dependiente).
- ▶ **X**: Atributos técnicos de la canción (variables independientes).
- ▶ β : Coeficientes que representan el impacto de cada atributo en la popularidad.
- ▶ ϵ : Variable que indica el margen de error que se tiene.

Paradigma y Justificación del Modelo

El desafío de predecir la popularidad de una canción usando de base sus atributos técnicos se aborda mediante un modelo de **regresión lineal**.

Regresión Lineal

Es un modelo matemático que busca representar una relación lineal entre una variable dependiente **Y** y una o más variables independientes **X**.

Matemáticamente, se expresa como: $Y = X\beta + \epsilon$

Para este caso, se tiene que:

- ▶ **Y**: Popularidad de la canción (variable dependiente).
- ▶ **X**: Atributos técnicos de la canción (variables independientes).
- ▶ β : Coeficientes que representan el impacto de cada atributo en la popularidad.
- ▶ ϵ : Variable que indica el margen de error que se tiene.

Paradigma y Justificación del Modelo

El desafío de predecir la popularidad de una canción usando de base sus atributos técnicos se aborda mediante un modelo de **regresión lineal**.

Regresión Lineal

Es un modelo matemático que busca representar una relación lineal entre una variable dependiente **Y** y una o más variables independientes **X**.

Matemáticamente, se expresa como: $Y = X\beta + \epsilon$

Para este caso, se tiene que:

- ▶ **Y**: Popularidad de la canción (variable dependiente).
- ▶ **X**: Atributos técnicos de la canción (variables independientes).
- ▶ β : Coeficientes que representan el impacto de cada atributo en la popularidad.
- ▶ ϵ : Variable que indica el margen de error que se tiene.

Paradigma y Justificación del Modelo

El desafío de predecir la popularidad de una canción usando de base sus atributos técnicos se aborda mediante un modelo de **regresión lineal**.

Regresión Lineal

Es un modelo matemático que busca representar una relación lineal entre una variable dependiente **Y** y una o más variables independientes **X**.

Matemáticamente, se expresa como: $Y = X\beta + \epsilon$

Para este caso, se tiene que:

- ▶ **Y**: Popularidad de la canción (variable dependiente).
- ▶ **X**: Atributos técnicos de la canción (variables independientes).
- ▶ β : Coeficientes que representan el impacto de cada atributo en la popularidad.
- ▶ ϵ : Variable que indica el margen de error que se tiene.

Paradigma y Justificación del Modelo

La elección de un modelo de regresión lineal se basa en las siguientes consideraciones:

- ▶ Contexto del Análisis: El tipo de variable objetivo (popularidad) es numérica, lo que hace que el problema sea naturalmente de regresión, siendo la regresión lineal uno de los modelos más básicos para este tipo de tareas.
- ▶ Facilidad de Observación: Se puede observar el aumento de la popularidad a medida que incrementan atributos clave como la disponibilidad.
- ▶ Detección de Linealidad: El modelo fue útil para identificar relaciones lineales y no lineales entre los atributos técnicos y la popularidad.

Paradigma y Justificación del Modelo

La elección de un modelo de regresión lineal se basa en las siguientes consideraciones:

- ▶ Contexto del Análisis: El tipo de variable objetivo (popularidad) es numérica, lo que hace que el problema sea naturalmente de regresión, siendo la regresión lineal uno de los modelos más básicos para este tipo de tareas.
- ▶ Facilidad de Observación: Se puede observar el aumento de la popularidad a medida que incrementan atributos clave como la disponibilidad.
- ▶ Detección de Linealidad: El modelo fue útil para identificar relaciones lineales y no lineales entre los atributos técnicos y la popularidad.

Paradigma y Justificación del Modelo

La elección de un modelo de regresión lineal se basa en las siguientes consideraciones:

- Contexto del Análisis: El tipo de variable objetivo (popularidad) es numérica, lo que hace que el problema sea naturalmente de regresión, siendo la regresión lineal uno de los modelos más básicos para este tipo de tareas.
- Facilidad de Observación: Se puede observar el aumento de la popularidad a medida que incrementan atributos clave como la disponibilidad.
- Detección de Linealidad: El modelo fue útil para identificar relaciones lineales y no lineales entre los atributos técnicos y la popularidad.

Entrenamiento del Modelo

- El entrenamiento del modelo de regresión fue realizado como un modelo de regresión clásico, es decir, que no posee regularización.
- Se generaron las respectivas predicciones con los datos.
- Se evaluó el rendimiento del modelo utilizando 2 métricas: el error cuadrático medio de la raíz el coeficiente de determinación.

```
modelo_lr = LinearRegression()
modelo_lr.fit(X_train_scaled, y_train)

y_pred_lr = modelo_lr.predict(X_test_scaled)

rmse_lr = np.sqrt(mean_squared_error(y_test, y_pred_lr))

r2_lr = r2_score(y_test, y_pred_lr)

print("=== RESULTADOS DE EVALUACIÓN ===")
print(f"REGRESIÓN LINEAL CLÁSICA - RMSE: {rmse_lr:.4f} | R2: {r2_lr:.4f}")
```

```
=== RESULTADOS DE EVALUACIÓN ===
REGRESIÓN LINEAL CLÁSICA - RMSE: 19.2854 | R2: 0.0566
```

Figura: Algoritmo de entrenamiento.

Evaluación del Modelo

- En el proceso de evaluación, primeramente, se seleccionaron las variables y coeficientes más relevantes para la predicción de la popularidad.

```
columnas_principales = X.columns[:11]
```

```
coef_lr = modelo_lr.coef_[:11]
```

Figura: Variables y coeficientes más relevantes.

- Posteriormente, para poder realizar la evaluación, se utilizó un gráfico de barras en el cual se tiene en el eje X un valor representa el impacto en la popularidad de la canción y en el eje Y se tienen las características tomadas para la evaluación.

Evaluación del Modelo

- En el proceso de evaluación, primeramente, se seleccionaron las variables y coeficientes más relevantes para la predicción de la popularidad.

```
columnas_principales = X.columns[:11]
```

```
coef_lr = modelo_lr.coef_[:11]
```

Figura: Variables y coeficientes más relevantes.

- Posteriormente, para poder realizar la evaluación, se utilizó un gráfico de barras en el cual se tiene en el eje X un valor representa el impacto en la popularidad de la canción y en el eje Y se tienen las características tomadas para la evaluación.

Evaluación del Modelo




Figura: Diagrama de evaluación del modelo.

Los valores negativos del eje X representan un impacto negativo en la popularidad, mientras que los valores positivos representan un impacto positivo. En este caso, se puede observar que la característica con mayor impacto positivo es la "danceability", mientras que la característica con mayor impacto negativo es "instrumentalness". Esto sugiere que las canciones con mayor "danceability" tienden a ser más populares, mientras que las canciones con mayor "instrumentalness" tienden a ser menos populares.

Simulación del Modelo

- Para este proceso se simuló la toma de 5 canciones del dataset original para así realizar la predicción de su popularidad utilizando el modelo.

```
dataset_nuevas_canciones = df.sample(n=5, random_state=SEED)

predicciones_exito = predecir_exito_musical(
    nuevos_datos=dataset_nuevas_canciones,
    modelo=modelo_lr,
    scaler=scaler,
    columnas_esperadas=columnas_entrenamiento
)
```

Figura: Código de simulación del modelo.

Simulación del Modelo

- Luego, al momento de mostrar los resultados, se toma en cuenta la popularidad real de cada canción, para así poder realizar la comparación con la popularidad predicha por el modelo.

```
resultados_demo = pd.DataFrame({  
    'Canción': dataset_nuevas_canciones['track_name'].values,  
    'Artista': dataset_nuevas_canciones['artists'].values,  
    'Popularidad Real': dataset_nuevas_canciones['popularity'].values,  
    'Popularidad Predicha': predicciones_exito  
})  
  
resultados_demo['Margen de Error Absoluto'] = abs(resultados_demo['Popularidad Real'] - resultados_demo['Popularidad Predicha'])  
  
resultados_demo
```

Figura: Código de simulación del modelo.

Simulación del Modelo

- Los resultados obtenidos de la simulación son los siguientes:

	Canción	Artista	Popularidad Real	Popularidad Predicha	Margen de Error Absoluto
0	Solo	Clean Bandit; Demi Lovato	5	43.22	38.22
1	Mich hat ein Engel geküsst	Mickie Krause	0	34.08	34.08
2	Tritonia - Intro	Tritonal	20	29.99	9.99
3	Love Till It's Over (feat. MKLA)	DVBBS; MKLA	57	47.12	9.88
4	Adadada Arrambame	Yuvan Shankar Raja; Shankar Mahadevan	49	36.13	12.87

Figura: Resultados de la simulación del modelo.

Comparación del Modelo

- Por último, se realizó una segunda versión del modelo agregando las dimensiones semánticas (categorías) obtenidas anteriormente para determinar si existe alguna mejora del mismo. Los resultados se muestran en la siguiente tabla:

	Métrica	Modelo V1 (Base)	Modelo V2 (Atributos Textuales)
0	RMSE	19.285396	19.320173
1	R2	0.056633	0.053227

Figura: Comparación de modelos.

Comparación del Modelo

- ▶ De esta comparación se determinó que la nueva versión del modelo presenta un menor rendimiento en comparación al original. Dicho empeoramiento puede deberse a:
 - ▶ Baja Correlación Lineal: El modelo busca relaciones directas: "Mientras más triste, más popular". Pero la música no funciona de esa manera. De modo que, las variables nuevas pueden haber aportado más ruido que alguna mejora directa en la predicción.
 - ▶ Ruido en los títulos de las canciones: El título de la canción no representa necesariamente su contenido o estilo.
 - ▶ Popularidad Multicausal: La popularidad depende de factores que el conjunto de datos no tiene, como el marketing, fama del artista, tendencias musicales, entre otros.

Comparación del Modelo

- ▶ De esta comparación se determinó que la nueva versión del modelo presenta un menor rendimiento en comparación al original. Dicho empeoramiento puede deberse a:
 - ▶ Baja Correlación Lineal: El modelo busca relaciones directas: "Mientras más triste, más popular". Pero la música no funciona de esa manera. De modo que, las variables nuevas pueden haber aportado más ruido que alguna mejora directa en la predicción.
 - ▶ Ruido en los títulos de las canciones: El título de la canción no representa necesariamente su contenido o estilo.
 - ▶ Popularidad Multicausal: La popularidad depende de factores que el conjunto de datos no tiene, como el marketing, fama del artista, tendencias musicales, entre otros.

Comparación del Modelo

- ▶ De esta comparación se determinó que la nueva versión del modelo presenta un menor rendimiento en comparación al original. Dicho empeoramiento puede deberse a:
 - ▶ Baja Correlación Lineal: El modelo busca relaciones directas: "Mientras más triste, más popular". Pero la música no funciona de esa manera. De modo que, las variables nuevas pueden haber aportado más ruido que alguna mejora directa en la predicción.
 - ▶ Ruido en los títulos de las canciones: El título de la canción no representa necesariamente su contenido o estilo.
 - ▶ Popularidad Multicausal: La popularidad depende de factores que el conjunto de datos no tiene, como el marketing, fama del artista, tendencias musicales, entre otros.

Estrategia Basada en Evidencia para el Éxito de Contenidos

Conclusiones

Con base en el estudio realizado, se tiene entonces que, el modelo de regresión lineal proporciona una aproximación inicial para entender la relación entre los atributos técnicos de las canciones y su popularidad.

Esta aproximación inicial es valiosa para identificar tendencias generales y patrones en los datos. Entre estos patrones, se destacan los siguientes:

- ▶ El oyente busca una experiencia sonora vibrante.
- ▶ La gran popularidad se concentra en canciones que no sean instrumentales.
- ▶ Existe una preferencia por grabaciones de estudio y sonidos menos orgánicos.

Este modelo puede ser una herramienta útil para Spotify al momento de tomar decisiones estratégicas sobre qué canciones promover o recomendar a los usuarios.

Referencias

Huerta, I. (s.f.). *Domina los Embeddings : La clave para el análisis semántico de contenidos, textos, documentaciones y keywords*. <https://ikaue.com/blog-data/embeddings-de-texto-la-clave-para-el-analisis-semantico-y-de-significados-seo>

Word Embeddings in NLP. (2025, 23 de Julio). GeekforGeeks.
<https://www.geeksforgeeks.org/nlp/word-embeddings-in-nlp/>

¡Muchas Gracias!