



Presentación de Minería de datos Spotify Tracks Dataset

Rafael Contreras Agudelo
Edwyn Guzmán
Yarima Contreras Blanco

6213 - Minería de datos
Facultad de ciencias
Universidad Central de Venezuela

28 de febrero de 2026

Contenido

- 1 Introducción y Objetivos
- 2 Metodología CRISP-DM
- 3 Comprensión del Negocio y los Datos
- 4 Preprocesamiento de Datos
- 5 Análisis Exploratorio de Datos (EDA)
- 6 Modelado y Evaluación
- 7 Conclusiones

"Notoriamente no hay clasificación del universo que no sea arbitraria y conjetural."^a

^aEl idioma analítico de John Wilkins - Jorge Luis Borges

Introducción y Objetivos

Introducción: Contexto del Negocio

- ▶ **Decisión de Inversión:** En la industria musical, predecir si un track será un éxito es vital para determinar el destino de los recursos.
- ▶ **Plataformas Digitales:** Spotify genera millones de puntos de datos diarios sobre el comportamiento del usuario.
- ▶ **Competitividad:** Con miles de lanzamientos diarios, destacar un track requiere más que solo intuición artística.

Oportunidad

El uso de **Minería de Datos** permite transformar características musicales en ventajas competitivas para sellos y artistas.

Definición del Problema

Desafío Predecir el éxito (popularidad) de una canción antes o durante su lanzamiento.

Incertidumbre Las inversiones en marketing musical suelen ser de alto riesgo sin un respaldo analítico de los datos.

Pregunta de Investigación:

¿Es posible determinar el *ranking* de una canción basándose en sus atributos técnicos como el tempo, la energía y la disponibilidad?

Objetivos

Objetivo General:

- ▶ Aplicar el proceso de minería de datos para predecir el ranking de tracks de Spotify utilizando la metodología CRISP-DM.

Objetivos Específicos:

- ▶ Ejecutar el preprocesamiento y limpieza del dataset.
- ▶ Realizar un análisis exploratorio de datos (EDA) para identificar patrones y relaciones entre variables.
- ▶ Desarrollar un modelo predictivo para pronosticar el ranking de una canción.

Metodología CRISP-DM

Metodología CRISP-DM: Características

- **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Metodología CRISP-DM: Características

- ▶ **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- ▶ **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- ▶ **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Metodología CRISP-DM: Características

- ▶ **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- ▶ **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- ▶ **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Justificación de la Metodología

Motivo de elección

Se selecciona esta metodología por su capacidad para estructurar un proceso completo desde la comprensión del negocio y de los datos técnicos hasta la predicción de resultados.

Ventajas de su utilización:

1. **Flexibilidad:** Ideal para ajustar el preprocesamiento de variables acústicas según los hallazgos del EDA.
2. **Evaluación Continua:** Permite validar si las métricas de regresión responden correctamente a la meta de negocio (predecir el ranking).
3. **Estructura:** Facilita la transición entre el análisis exploratorio y el modelado de regresión propuesto.

Comprensión del Negocio y los Datos

Fase I: Comprensión del Negocio

Objetivo de Minería de Datos

Transformar los atributos acústicos de los tracks en un valor numérico de **popularity** mediante un modelo de **regresión**, permitiendo predecir el rendimiento comercial de una canción.

Criterios de Éxito del Proyecto:

- ▶ **Técnico:** Lograr un modelo con un margen de error aceptable que permita diferenciar canciones con alto potencial de aquellas con bajo impacto.
- ▶ **De Negocio:** Identificar los patrones históricos que correlacionan el "sonido" (variables flotantes) con el éxito, para reducir el riesgo en la toma de decisiones de inversión.

Meta Final:

Generar una herramienta analítica que determine si una canción será un éxito basándose en su composición técnica.

Fase II: Comprensión de los Datos

Origen del Dataset: Spotify Tracks Dataset ([Kaggle](#)).

- **Observaciones:** 114.000 registros.
- **Variables:** 21 columnas.

Esquema del dataset:

Tipo de Dato	Variables
Entero (int64)	#, popularity, duration_ms, key, mode, time_signature
Texto (object)	track_id, artists, album_name, track_name, track_genre
Lógico (bool)	explicit
Flotante (float64)	danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo

Tabla: Tipos de datos por columna del dataset escogido.

Fase II: Comprensión de los Datos

Previsualización de los Datos:

	Unnamed: 0	track_id	artists	album_name	track_name	popularity	duration_ms	explicit	danceability	energy
0	0	5SuOikwiRyPMVolQDJUgSV	Gen Hoshino	Comedy	Comedy	73	230866	False	0.676	0.4610
1	1	4qPNDBW1i3p13qLCi0K3A	Ben Woodward	Ghost (Acoustic)	Ghost - Acoustic	55	149610	False	0.420	0.1660
2	2	1UBSr7s7jYXzM8EGcbK5b	Ingrid Michaelson:ZAYN	To Begin Again	To Begin Again	57	210826	False	0.438	0.3590
3	3	6lfxq3CG4xtTIEg7opyCyx	Kina Grannis	Crazy Rich Asians (Original Motion Picture Sou...	Can't Help Falling In Love	71	201933	False	0.266	0.0596
4	4	5vjLSffimIP26QG5WcN2K	Chord Overstreet	Hold On	Hold On	82	198853	False	0.618	0.4430
key	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature	track_genre
1	-6.746	0	0.1430	0.0322	0.000001	0.3580	0.715	87.917	4	acoustic
1	-17.235	1	0.0763	0.9240	0.000006	0.1010	0.267	77.489	4	acoustic
0	-9.734	1	0.0557	0.2100	0.000000	0.1170	0.120	76.332	4	acoustic
0	-18.515	1	0.0363	0.9050	0.000071	0.1320	0.143	181.740	3	acoustic
2	-9.681	1	0.0526	0.4690	0.000000	0.0829	0.167	119.949	4	acoustic

Figura: Impresión de los primeros registros del dataset.

Preprocesamiento de Datos

Preprocesamiento: Valores Faltantes

	Nulos	Porcentaje (%)
artists	1	0.000877
track_name	1	0.000877
album_name	1	0.000877
Unnamed: 0	0	0.000000
track_id	0	0.000000
popularity	0	0.000000
duration_ms	0	0.000000
explicit	0	0.000000
danceability	0	0.000000
energy	0	0.000000
key	0	0.000000
loudness	0	0.000000
mode	0	0.000000
speechiness	0	0.000000
acousticness	0	0.000000
instrumentalness	0	0.000000
liveness	0	0.000000
valence	0	0.000000
tempo	0	0.000000
time_signature	0	0.000000
track_genre	0	0.000000

Figura: Cantidad y porcentaje de valores faltantes por columna.

Tratamiento de Datos:

- **Limpieza Inicial:** Identificación de valores nulos en cada campo del dataset.
- **Estrategia:** Dado el bajo porcentaje de nulos y su poca relevancia para el análisis, se opta por eliminar las filas con valores faltantes. Esto también permite la utilización de un modelo de regresión.

Preprocesamiento: Valores Faltantes

	Nulos	Porcentaje (%)
artists	1	0.000877
track_name	1	0.000877
album_name	1	0.000877
Unnamed: 0	0	0.000000
track_id	0	0.000000
popularity	0	0.000000
duration_ms	0	0.000000
explicit	0	0.000000
danceability	0	0.000000
energy	0	0.000000
key	0	0.000000
loudness	0	0.000000
mode	0	0.000000
speechiness	0	0.000000
acousticness	0	0.000000
instrumentalness	0	0.000000
liveness	0	0.000000
valence	0	0.000000
tempo	0	0.000000
time_signature	0	0.000000
track_genre	0	0.000000

Figura: Cantidad y porcentaje de valores faltantes por columna.

Tratamiento de Datos:

- **Limpieza Inicial:** Identificación de valores nulos en cada campo del dataset.
- **Estrategia:** Dado el bajo porcentaje de nulos y su poca relevancia para el análisis, se opta por eliminar las filas con valores faltantes. Esto también permite la utilización de un modelo de regresión.

Preprocesamiento: Variables No Relevantes

- **Limpieza de nulos:** Se ejecuta la eliminación de filas con valores faltantes.
- **Limpieza de variables no relevantes:** Se descartan las columnas que no aportan información útil para el modelo predictivo, como los IDs, nombres y géneros de canciones.

Dimensiones resultantes: 113.999 registros y 14 columnas.

```
# Eliminar filas con valores nulos (NaN)
df_clean = df.dropna()

# Eliminar variables de identificación y texto libre (Ruido)
columnas_a_eliminar = ['Unnamed: 0', 'track_id', 'artists', 'album_name', 'track_name', 'track_genre', 'key']
df_clean = df_clean.drop(columns=columnas_a_eliminar)

print(f"Dimensiones tras la limpieza: {df_clean.shape}")
```

Dimensiones tras la limpieza: (113999, 14)

Figura: Limpieza Estructural del Dataset.

Preprocesamiento: Valores Lógicos

- **Valores Lógicos:** Los modelos de regresión necesitan variables numéricas. Por esta razón, se transforman los valores booleanos de la columna `explicit` a 0 (no explícito) y 1 (explícito).

	popularity	duration_ms	explicit	danceability	energy	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	73	230666	0	0.676	0.4610	-6.746	0	0.1430	0.0322	0.000001	0.3580	0.7150	87.917	4
1	55	149610	0	0.420	0.1660	-17.235	1	0.0763	0.9240	0.000006	0.1010	0.2670	77.489	4
2	57	210826	0	0.438	0.3590	-9.734	1	0.0557	0.2100	0.000000	0.1170	0.1200	76.332	4
3	71	201933	0	0.266	0.0596	-18.515	1	0.0363	0.9050	0.000071	0.1320	0.1430	181.740	3
4	82	198853	0	0.618	0.4430	-9.681	1	0.0526	0.4690	0.000000	0.0829	0.1670	119.949	4
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
113995	21	384999	0	0.172	0.2350	-16.393	1	0.0422	0.6400	0.928000	0.0863	0.0339	125.995	5
113996	22	385000	0	0.174	0.1170	-18.318	0	0.0401	0.9940	0.976000	0.1050	0.0350	85.239	4
113997	22	271466	0	0.629	0.3290	-10.895	0	0.0420	0.8670	0.000000	0.0839	0.7430	132.378	4
113998	41	283893	0	0.587	0.5060	-10.889	1	0.0297	0.3810	0.000000	0.2700	0.4130	135.960	4
113999	22	241826	0	0.526	0.4870	-10.204	0	0.0725	0.6810	0.000000	0.0893	0.7080	79.198	4

113999 rows x 14 columns

Figura: Transformación de Booleanos.

Análisis Exploratorio de Datos (EDA)

Tipos de conocimiento a extraer[1]

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ Agrupación
- ▶ Detección de anomalías
- ▶ Asociaciones



atr_i	...	atr_j	...	obj
⋮	...	⋮	...	⋮

Tipos de conocimiento a extraer

► Tareas descriptivas^a

- Caracterización de datos
- Discriminación de datos


► Tareas predictivas

- Clasificación
- Regresión

► Agrupación

► Detección de anomalías

► Asociaciones



^a[kaggle.com/search?q=eda](https://www.kaggle.com/search?q=eda)

Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ Agrupación
- ▶ Detección de anomalías
- ▶ Asociaciones

ID	...	$atributo_i$	$objetivo$
1	...	$val_{1,i}$	obj_1
2	...	$val_{2,i}$	obj_2

Tabla: Estructura ejemplo

$type(obj_i) = enum \rightarrow$ clasificación

$type(obj_i) = number \rightarrow$ regresión

Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ Agrupación
- ▶ Detección de anomalías
- ▶ Asociaciones


Ejemplo de aplicaciones

- ▶ Determinar la categoría de una página web
- ▶ Identificar el sentimiento predominante de un tweet
- ▶ Categorizar candidatos a créditos bancarios
- ▶ Estimar el costo de un inmueble
- ▶ Estimar el crecimiento de una compañía
- ▶ Estimar la popularidad de una canción en spotify^a

^a[hf.co/datasets/maharshipandya/spotify-tracks-dataset](https://www.kaggle.com/datasets/maharshipandya/spotify-tracks-dataset)


Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ **Agrupación**
- ▶ Detección de anomalías
- ▶ Asociaciones



Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ **Agrupación**
- ▶ Detección de anomalías
- ▶ Asociaciones



Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ Agrupación
- ▶ Detección de anomalías
- ▶ Asociaciones


Ejemplo de aplicaciones

- ▶ Segmentación de clientes
- ▶ Agrupación de tweets por semejanza semántica^a
- ▶ Agrupar estudiantes con desempeños similares

^a[sbert.net](https://www.sbert.net)

Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ Agrupación
- ▶ Detección de anomalías
- ▶ Asociaciones



Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ Agrupación
- ▶ Detección de anomalías
- ▶ Asociaciones

Ejemplo de aplicaciones

- ▶ Detección de ataques a servidores
- ▶ Detección de fraudes bancarios
- ▶ Identificar las fallas de un servicio de telefonía móvil

Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ Agrupación
- ▶ Detección de anomalías
- ▶ Asociaciones

Comprados juntos habitualmente



Este producto: CORSAIR
HARPOON - Mouse inalámbrico
RGB para juegos, 10,000 DPI, 6...
US\$49⁹⁹



CORSAIR Teclado mecánico K70
CORE RGB para juegos con
reposamanos - Interruptores...
US\$104⁹⁹



CORSAIR MM700 RGB -
Alfombrilla de mouse para juegos
de tela extendida, 36.6 x 15.8...
US\$52⁹⁸

Tipos de conocimiento a extraer

- ▶ Tareas descriptivas
 - ▶ Caracterización de datos
 - ▶ Discriminación de datos
- ▶ Tareas predictivas
 - ▶ Clasificación
 - ▶ Regresión
- ▶ Agrupación
- ▶ Detección de anomalías
- ▶ Asociaciones

Ejemplo de aplicaciones

- ▶ *"También te puede gustar"*
- ▶ Detección de ocurrencias probables/improbables

Modelado y Evaluación

Conclusiones

Resumen

Minería de datos

Descubrir conocimiento y/o patrones a partir de datos.*

Referencias

- [1] Jiawei Han, Micheline Kamber y Jian Pei. *Data mining concepts and techniques, third edition*. 2012.

¡Gracias!

dm-25.ucv.ai