



Presentación de Minería de datos Spotify Tracks Dataset

Rafael Contreras Agudelo
Edwyn Guzmán
Yarima Contreras Blanco

6213 - Minería de datos
Facultad de ciencias
Universidad Central de Venezuela

28 de febrero de 2026

Contenido

- 1 Introducción y Objetivos
- 2 Metodología CRISP-DM
- 3 Comprensión del Negocio y los Datos
- 4 Preprocesamiento de Datos
- 5 Análisis Exploratorio de Datos (EDA)
- 6 Modelado y Evaluación
- 7 Conclusiones

"Notoriamente no hay clasificación del universo que no sea arbitraria y conjetural."^a

^aEl idioma analítico de John Wilkins - Jorge Luis Borges

Introducción y Objetivos

Introducción: Contexto del Negocio

- ▶ **Decisión de Inversión:** En la industria musical, predecir si un track será un éxito es vital para determinar el destino de los recursos.
- ▶ **Plataformas Digitales:** Spotify genera millones de puntos de datos diarios sobre el comportamiento del usuario.
- ▶ **Competitividad:** Con miles de lanzamientos diarios, destacar un track requiere más que solo intuición artística.

Oportunidad

El uso de **Minería de Datos** permite transformar características musicales en ventajas competitivas para sellos y artistas.

Definición del Problema

Desafío Predecir el éxito (popularidad) de una canción antes o durante su lanzamiento.

Incertidumbre Las inversiones en marketing musical suelen ser de alto riesgo sin un respaldo analítico de los datos.

Pregunta de Investigación:

¿Es posible determinar el *ranking* de una canción basándose en sus atributos técnicos como el tempo, la energía y la disponibilidad?

Objetivos

Objetivo General:

- ▶ Aplicar el proceso de minería de datos para predecir el ranking de tracks de Spotify utilizando la metodología CRISP-DM.

Objetivos Específicos:

- ▶ Ejecutar el preprocesamiento y limpieza del dataset.
- ▶ Realizar un análisis exploratorio de datos (EDA) para identificar patrones y relaciones entre variables.
- ▶ Desarrollar un modelo predictivo para pronosticar el ranking de una canción.

Metodología CRISP-DM

Metodología CRISP-DM: Características

- **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Metodología CRISP-DM: Características

- **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Metodología CRISP-DM: Características

- ▶ **Estándar de la Industria:** Es el modelo de proceso más utilizado para proyectos de Minería de Datos.
- ▶ **Ciclo Iterativo:** Permite retroceder entre fases para garantizar la calidad del modelo final.
- ▶ **Enfoque en el Negocio:** No solo se centra en el algoritmo, sino en resolver un problema real.




Figura: Ciclo de vida CRISP-DM.

Justificación de la Metodología

Motivo de elección

Se selecciona esta metodología por su capacidad para estructurar un proceso completo desde la comprensión del negocio y de los datos técnicos hasta la predicción de resultados.

Ventajas de su utilización:

1. **Flexibilidad:** Ideal para ajustar el preprocesamiento de variables acústicas según los hallazgos del EDA.
2. **Evaluación Continua:** Permite validar si las métricas de regresión responden correctamente a la meta de negocio (predecir el ranking).
3. **Estructura:** Facilita la transición entre el análisis exploratorio y el modelado de regresión propuesto.

Comprensión del Negocio y los Datos

Fase I: Comprensión del Negocio

Objetivo de Minería de Datos

Transformar los atributos acústicos de los tracks en un valor numérico de **popularity** mediante un modelo de **regresión**, permitiendo predecir el rendimiento comercial de una canción.

Criterios de Éxito del Proyecto:

- ▶ **Técnico:** Lograr un modelo con un margen de error aceptable que permita diferenciar canciones con alto potencial de aquellas con bajo impacto.
- ▶ **De Negocio:** Identificar los patrones históricos que correlacionan el "sonido" (variables flotantes) con el éxito, para reducir el riesgo en la toma de decisiones de inversión.

Meta Final:

Generar una herramienta analítica que determine si una canción será un éxito basándose en su composición técnica.

Fase II: Comprensión de los Datos

Origen del Dataset: Spotify Tracks Dataset ([Kaggle](#)).

- **Observaciones:** 114.000 registros.
- **Variables:** 21 columnas.

Esquema del dataset:

Tipo de Dato	Variables
Entero (int64)	#, popularity, duration_ms, key, mode, time_signature
Texto (object)	track_id, artists, album_name, track_name, track_genre
Lógico (bool)	explicit
Flotante (float64)	danceability, energy, loudness, speechiness, acousticness, instrumentalness, liveness, valence, tempo

Tabla: Tipos de datos por columna del dataset escogido.

Fase II: Comprensión de los Datos

Previsualización de los Datos:

	Unnamed: 0	track_id	artists	album_name	track_name	popularity	duration_ms	explicit	danceability	energy
0	0	5SuOikwiRyPMVolQDJUgSV	Gen Hoshino	Comedy	Comedy	73	230866	False	0.676	0.4610
1	1	4qPNDBW1i3p13qLCi0K3A	Ben Woodward	Ghost (Acoustic)	Ghost - Acoustic	55	149610	False	0.420	0.1660
2	2	1UBSr7s7jYXzM8EGcbK5b	Ingrid Michaelson:ZAYN	To Begin Again	To Begin Again	57	210826	False	0.438	0.3590
3	3	6lfxq3CG4xtTIEg7opyCyx	Kina Grannis	Crazy Rich Asians (Original Motion Picture Sou...	Can't Help Falling In Love	71	201933	False	0.266	0.0596
4	4	5vjLSffimIP26QG5WcN2K	Chord Overstreet	Hold On	Hold On	82	198853	False	0.618	0.4430
key	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature	track_genre
1	-6.746	0	0.1430	0.0322	0.000001	0.3580	0.715	87.917	4	acoustic
1	-17.235	1	0.0763	0.9240	0.000006	0.1010	0.267	77.489	4	acoustic
0	-9.734	1	0.0557	0.2100	0.000000	0.1170	0.120	76.332	4	acoustic
0	-18.515	1	0.0363	0.9050	0.000071	0.1320	0.143	181.740	3	acoustic
2	-9.681	1	0.0526	0.4690	0.000000	0.0829	0.167	119.949	4	acoustic

Figura: Impresión de los primeros registros del dataset.

Preprocesamiento de Datos

Preprocesamiento: Valores Faltantes

	Nulos	Porcentaje (%)
artists	1	0.000877
track_name	1	0.000877
album_name	1	0.000877
Unnamed: 0	0	0.000000
track_id	0	0.000000
popularity	0	0.000000
duration_ms	0	0.000000
explicit	0	0.000000
danceability	0	0.000000
energy	0	0.000000
key	0	0.000000
loudness	0	0.000000
mode	0	0.000000
speechiness	0	0.000000
acousticness	0	0.000000
instrumentalness	0	0.000000
liveness	0	0.000000
valence	0	0.000000
tempo	0	0.000000
time_signature	0	0.000000
track_genre	0	0.000000

Figura: Cantidad y porcentaje de valores faltantes por columna.

Tratamiento de Datos:

- **Limpieza Inicial:** Identificación de valores nulos en cada campo del dataset.
- **Estrategia:** Dado el bajo porcentaje de nulos y su poca relevancia para el análisis, se opta por eliminar las filas con valores faltantes. Esto también permite la utilización de un modelo de regresión.

Preprocesamiento: Valores Faltantes

	Nulos	Porcentaje (%)
artists	1	0.000877
track_name	1	0.000877
album_name	1	0.000877
Unnamed: 0	0	0.000000
track_id	0	0.000000
popularity	0	0.000000
duration_ms	0	0.000000
explicit	0	0.000000
danceability	0	0.000000
energy	0	0.000000
key	0	0.000000
loudness	0	0.000000
mode	0	0.000000
speechiness	0	0.000000
acousticness	0	0.000000
instrumentalness	0	0.000000
liveness	0	0.000000
valence	0	0.000000
tempo	0	0.000000
time_signature	0	0.000000
track_genre	0	0.000000

Figura: Cantidad y porcentaje de valores faltantes por columna.

Tratamiento de Datos:

- **Limpieza Inicial:** Identificación de valores nulos en cada campo del dataset.
- **Estrategia:** Dado el bajo porcentaje de nulos y su poca relevancia para el análisis, se opta por eliminar las filas con valores faltantes. Esto también permite la utilización de un modelo de regresión.

Preprocesamiento: Variables No Relevantes

- **Limpieza de nulos:** Se ejecuta la eliminación de filas con valores faltantes.
- **Limpieza de variables no relevantes:** Se descartan las columnas que no aportan información útil para el modelo predictivo, como los IDs, nombres y géneros de canciones.

Dimensiones resultantes: 113.999 registros y 14 columnas.

```
# Eliminar filas con valores nulos (NaN)
df_clean = df.dropna()

# Eliminar variables de identificación y texto libre (Ruido)
columnas_a_eliminar = ['Unnamed: 0', 'track_id', 'artists', 'album_name', 'track_name', 'track_genre', 'key']
df_clean = df_clean.drop(columns=columnas_a_eliminar)

print(f"Dimensiones tras la limpieza: {df_clean.shape}")
```

Dimensiones tras la limpieza: (113999, 14)

Figura: Limpieza Estructural del Dataset.

Preprocesamiento: Valores Lógicos

- **Valores Lógicos:** Los modelos de regresión necesitan variables numéricas. Por esta razón, se transforman los valores booleanos de la columna `explicit` a 0 (no explícito) y 1 (explícito).

	popularity	duration_ms	explicit	danceability	energy	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	73	230666	0	0.676	0.4610	-6.746	0	0.1430	0.0322	0.000001	0.3580	0.7150	87.917	4
1	55	149610	0	0.420	0.1660	-17.235	1	0.0763	0.9240	0.000006	0.1010	0.2670	77.489	4
2	57	210826	0	0.438	0.3590	-9.734	1	0.0557	0.2100	0.000000	0.1170	0.1200	76.332	4
3	71	201933	0	0.266	0.0596	-18.515	1	0.0363	0.9050	0.000071	0.1320	0.1430	181.740	3
4	82	198853	0	0.618	0.4430	-9.681	1	0.0526	0.4690	0.000000	0.0829	0.1670	119.949	4
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
113995	21	384999	0	0.172	0.2350	-16.393	1	0.0422	0.6400	0.928000	0.0863	0.0339	125.995	5
113996	22	385000	0	0.174	0.1170	-18.318	0	0.0401	0.9940	0.976000	0.1050	0.0350	85.239	4
113997	22	271466	0	0.629	0.3290	-10.895	0	0.0420	0.8670	0.000000	0.0839	0.7430	132.378	4
113998	41	283893	0	0.587	0.5060	-10.889	1	0.0297	0.3810	0.000000	0.2700	0.4130	135.960	4
113999	22	241826	0	0.526	0.4870	-10.204	0	0.0725	0.6810	0.000000	0.0893	0.7080	79.198	4

113999 rows x 14 columns

Figura: Transformación de Booleanos.

Análisis Exploratorio de Datos (EDA)

EDA: Estadísticas Descriptivas

Descriptores estadísticos de media, mediana, desviación estándar, mínimo y máximo para cada variable numérica del dataset.

► **Popularidad:**

Media de 33.2 con alta desviación estándar, indicando una gran dispersión en el éxito de los tracks.

	media	mediana	desv_estandar	min	max
popularity	33.238535	35.000000	22.305078	0.000	100.000
duration_ms	228029.153114	212906.000000	107297.712645	0.000	5237295.000
danceability	0.566800	0.580000	0.173542	0.000	0.985
energy	0.641383	0.685000	0.251529	0.000	1.000
key	5.309140	5.000000	3.559987	0.000	11.000
loudness	-8.258960	-7.004000	5.029337	-49.531	4.532
mode	0.637553	1.000000	0.480709	0.000	1.000
speechiness	0.084652	0.048900	0.105732	0.000	0.965
acousticness	0.314910	0.169000	0.332523	0.000	0.996
instrumentalness	0.156050	0.000042	0.309555	0.000	1.000
liveness	0.213553	0.132000	0.190378	0.000	1.000
valence	0.474068	0.464000	0.259261	0.000	0.995
tempo	122.147837	122.017000	29.978197	0.000	243.372
time_signature	3.904035	4.000000	0.432621	0.000	5.000

Figura: Estadísticas descriptivas.

EDA: Estadísticas Descriptivas

Descriptores estadísticos de media, mediana, desviación estándar, mínimo y máximo para cada variable numérica del dataset.

- **Duración:** El promedio se sitúa en ≈ 228 s (3.8 min). Se detectan valores máximos extremos que sugieren presencia de *outliers*.

	media	mediana	desv_estandar	min	max
popularity	33.238535	35.000000	22.305078	0.000	100.000
duration_ms	228029.153114	212906.000000	107297.712645	0.000	5237295.000
danceability	0.566800	0.580000	0.173542	0.000	0.985
energy	0.641383	0.685000	0.251529	0.000	1.000
key	5.309140	5.000000	3.559987	0.000	11.000
loudness	-8.258960	-7.004000	5.029337	-49.531	4.532
mode	0.637553	1.000000	0.480709	0.000	1.000
speechiness	0.084652	0.048900	0.105732	0.000	0.965
acousticness	0.314910	0.169000	0.332523	0.000	0.996
instrumentalness	0.156050	0.000042	0.309555	0.000	1.000
liveness	0.213553	0.132000	0.190378	0.000	1.000
valence	0.474068	0.464000	0.259261	0.000	0.995
tempo	122.147837	122.017000	29.978197	0.000	243.372
time_signature	3.904035	4.000000	0.432621	0.000	5.000

Figura: Estadísticas descriptivas.

EDA: Estadísticas Descriptivas

Descriptores estadísticos de media, mediana, desviación estándar, mínimo y máximo para cada variable numérica del dataset.

- **Variabilidad:** La amplitud de rangos en *energy* y *danceability* asegura una base de aprendizaje diversa para el modelo de regresión.

	media	mediana	desv_estandar	min	max
popularity	33.238535	35.000000	22.305078	0.000	100.000
duration_ms	228029.153114	212906.000000	107297.712645	0.000	5237295.000
danceability	0.566800	0.580000	0.173542	0.000	0.985
energy	0.641383	0.685000	0.251529	0.000	1.000
key	5.309140	5.000000	3.559987	0.000	11.000
loudness	-8.258960	-7.004000	5.029337	-49.531	4.532
mode	0.637553	1.000000	0.480709	0.000	1.000
speechiness	0.084652	0.048900	0.105732	0.000	0.965
acousticness	0.314910	0.169000	0.332523	0.000	0.996
instrumentalness	0.156050	0.000042	0.309555	0.000	1.000
liveness	0.213553	0.132000	0.190378	0.000	1.000
valence	0.474068	0.464000	0.259261	0.000	0.995
tempo	122.147837	122.017000	29.978197	0.000	243.372
time_signature	3.904035	4.000000	0.432621	0.000	5.000

Figura: Estadísticas descriptivas.

EDA: Análisis de Distribución

Se tiene que $y \in \mathbb{R}^n$, con $y_i \in [0, 100]$ representa la popularidad real de una canción i . Su distribución permite observar su comportamiento para la toma de decisiones.




Figura: Distribución de la popularidad.

EDA: Análisis de Distribución




Figura: Distribución de la popularidad.

- **Distribución Asimétrica:** Se observa un sesgo a la derecha (*Right-Skewed*), con una alta concentración en el rango $[0, 50]$.
- **Fenómeno Long-Tail:** La presencia de "éxitos" (popularidad > 80) es estadísticamente baja, reflejando la realidad del mercado musical.
- **Punto Crítico (Popularidad 0):** Existe un pico en el valor mínimo, atribuible a lanzamientos recientes o nichos sin tracción comercial.

EDA: Análisis de Distribución




Figura: Distribución de la popularidad.

- **Distribución Asimétrica:** Se observa un sesgo a la derecha (*Right-Skewed*), con una alta concentración en el rango $[0, 50]$.
- **Fenómeno Long-Tail:** La presencia de "éxitos" (popularidad > 80) es estadísticamente baja, reflejando la realidad del mercado musical.
- **Punto Crítico (Popularidad 0):** Existe un pico en el valor mínimo, atribuible a lanzamientos recientes o nichos sin tracción comercial.

EDA: Análisis de Distribución




Figura: Distribución de la popularidad.

- **Distribución Asimétrica:** Se observa un sesgo a la derecha (*Right-Skewed*), con una alta concentración en el rango $[0, 50]$.
- **Fenómeno Long-Tail:** La presencia de "éxitos" (popularidad > 80) es estadísticamente baja, reflejando la realidad del mercado musical.
- **Punto Crítico (Popularidad 0):** Existe un pico en el valor mínimo, atribuible a lanzamientos recientes o nichos sin tracción comercial.

EDA: Análisis de Correlación

Se implementa un Heatmap para visualizar la matriz de correlación entre las variables numéricas del dataset, con el objetivo de identificar relaciones lineales que puedan ser aprovechadas por el modelo de regresión.




Figura: Matriz de correlación.

EDA: Análisis de Correlación




Figura: Matriz de correlación.

- **Multicolinealidad:** Se observa una fuerte correlación positiva entre *energy* y *loudness*.
- Relación con el Target: La popularidad no muestra una dependencia lineal fuerte con una única variable.
- Correlación Negativa: Atributos como *acousticness* e *instrumentalness* tienden a oponerse a la energía del track.

EDA: Análisis de Correlación




Figura: Matriz de correlación.

- **Multicolinealidad:** Se observa una fuerte correlación positiva entre *energy* y *loudness*.
- **Relación con el Target:** La popularidad no muestra una dependencia lineal fuerte con una única variable.
- **Correlación Negativa:** Atributos como *acousticness* e *instrumentalness* tienden a oponerse a la energía del track.

EDA: Análisis de Correlación




Figura: Matriz de correlación.

- **Multicolinealidad:** Se observa una fuerte correlación positiva entre *energy* y *loudness*.
- **Relación con el Target:** La popularidad no muestra una dependencia lineal fuerte con una única variable.
- **Correlación Negativa:** Atributos como *acousticness* e *instrumentalness* tienden a oponerse a la energía del track.

EDA: Análisis de Correlación

Para el par de variables con mayor correlación positiva, se realiza un análisis de dispersión para evaluar la relación lineal entre ellas.




Figura: Análisis de dispersión entre *energy* y *loudness*.

EDA: Análisis de Correlación




Figura: Análisis de dispersión entre *energy* y *loudness*.

- ▶ **Multicolinealidad Detectada:** Alta correlación positiva entre *energy* y *loudness*. Se evaluará el uso de solo una para evitar redundancia en el modelo.
- ▶ **Complejidad del Target:** La popularidad no presenta una dependencia lineal fuerte con ninguna variable individual, sugiriendo un fenómeno multivariado.
- ▶ **Relaciones Inversas:** Se confirma una correlación negativa lógica entre *acousticness* frente a *energy* y *loudness*.

EDA: Análisis de Correlación




Figura: Análisis de dispersión entre *energy* y *loudness*.

- ▶ **Multicolinealidad Detectada:** Alta correlación positiva entre *energy* y *loudness*. Se evaluará el uso de solo una para evitar redundancia en el modelo.
- ▶ **Complejidad del Target:** La popularidad no presenta una dependencia lineal fuerte con ninguna variable individual, sugiriendo un fenómeno multivariado.
- ▶ **Relaciones Inversas:** Se confirma una correlación negativa lógica entre *acousticness* frente a *energy* y *loudness*.

EDA: Análisis de Correlación




Figura: Análisis de dispersión entre *energy* y *loudness*.

- ▶ **Multicolinealidad Detectada:** Alta correlación positiva entre *energy* y *loudness*. Se evaluará el uso de solo una para evitar redundancia en el modelo.
- ▶ **Complejidad del Target:** La popularidad no presenta una dependencia lineal fuerte con ninguna variable individual, sugiriendo un fenómeno multivariado.
- ▶ **Relaciones Inversas:** Se confirma una correlación negativa lógica entre *acousticness* frente a *energy* y *loudness*.

EDA: Análisis de Valores Atípicos (Outliers)

Creo que se podría agregar un gráfico de boxplot para destacar los outliers y justificar luego la decisión del tratamiento que elimina los 0s.




Figura: Para el gráfico de caja y bigotes.

EDA: Decisiones de Tratamiento

► Tratamiento del Sesgo (Target)

- Eliminación selectiva de registros con popularidad 0 para evitar el sesgo predictivo.

► Selección de Características

- Remoción de loudness por multicolinealidad con energy.
- Exclusión de key debido a su nula correlación con el éxito.

► Partición y Escalado

- División 80/20 (Train/Test).
- *StandardScaler* para normalizar magnitudes y evitar el *Data Leakage*.




Figura: Reducción de ruido en el target.

EDA: Decisiones de Tratamiento

► Tratamiento del Sesgo (Target)

- Eliminación selectiva de registros con popularidad 0 para evitar el sesgo predictivo.

► Selección de Características

- Remoción de loudness por multicolinealidad con energy.
- Exclusión de key debido a su nula correlación con el éxito.

► Partición y Escalado

- División 80/20 (Train/Test).
- *StandardScaler* para normalizar magnitudes y evitar el *Data Leakage*.




Figura: Matriz de características optimizada.

EDA: Decisiones de Tratamiento

► Tratamiento del Sesgo (Target)

- Eliminación selectiva de registros con popularidad 0 para evitar el sesgo predictivo.

► Selección de Características

- Remoción de loudness por multicolinealidad con energy.
- Exclusión de key debido a su nula correlación con el éxito.

► Partición y Escalado

- División 80/20 (Train/Test).
- *StandardScaler* para normalizar magnitudes y evitar el *Data Leakage*.




Figura: Pipeline de preparación de datos.

Modelado y Evaluación

Entrenamiento del Modelo

Lalala

Evaluación del Modelo

Lalala

Despliegue del Modelo

Lalala

Simulación del Modelo

Lalala

Conclusiones

Resumen

Minería de datos

Descubrir conocimiento y/o patrones a partir de datos.*

Referencias

¡Gracias!

dm-25.ucv.ai